

9 机器学习基础

模型未知，从数据学参数并预测 unseen data。监督（分类/回归）、无监督（聚类/降维/密度）、强化学习。**No-Free-Lunch**: 泛化必需归纳偏置，无算法对所有分布都最好。

训练集学参数；验证集选模型/超参数；测试集只作最终一次泛化评估。预处理统计量也只能由训练集估计。特征应突出类别差异并对无关变换不敏感。

Naive Bayes

给定 Y , F_i 条件独立：

$$P(Y, F_{1:n}) = P(Y) \prod_i P(F_i \mid Y),$$
$$\hat{y} = \arg \max_y [\log P(y) + \sum_i \log P(f_i \mid y)].$$

频数估计 $P(y) = c(y)/N$ ；只分类无需归一化，求后验再除 $\sum_y s_y$ 。取 $\log$ 防下溢且不改 argmax 。Bag-of-Words 共享 $P(W \mid Y)$ 、忽略词序。

加 k 平滑： $P_k(x \mid y) = \frac{c(x, y) + k}{c(y) + k|X|}$ ； $k = 1$ 为 Laplace，防零概率； $k \rightarrow \infty$ 趋均匀； k 用验证集选。NB 是生成式概率模型；强独立假设把参数量从指数降为近线性。

线性分类：Perceptron / SVM

得分 $a = w^T f(x)$ ，边界 $w^T f = 0$ ，偏置可作常数特征。二分类误判才更新 $w \leftarrow w + y^* f(x)$ 。多类 $\hat{y} = \operatorname{argmax}_y w_y^T f$ ；错时 $w_{y^+} + = f, w_{\hat{y}} - = f$ 。感知机为错误驱动判别式，主要输出类别/分数。

硬间隔 SVM： $\min_w \frac{1}{2} \|w\|^2$ s.t. $y_i w^T f_i \geq 1$ ；最大化几何间隔。支持向量是距边界最近、决定边界的点；感知机只求可分超平面，SVM 进一步最大间隔。**MIRA**：错分时取最小步长 τ 使正确类比分错类至少高 1，并限制 $\tau \leq C$ ，比固定步长更稳。**核技巧**：若只

用点积，可用 $K(x, z) = \phi(x)^T \phi(z)$ 替换；核化分类分数常形如 $\sum_i \alpha_i y_i K(x_i, x)$ ，无需显式高维 ϕ 。

K-NN 与距离

1-NN 复制最近样本标签；K-NN 多数/距离加权投票，几乎不训练但存储大、预测慢。 K 小：低偏差高方差/易过拟合；大则更平滑/易欠拟合，用验证集选。非参数不等于无超参数。单位向量点积 $\operatorname{sim} = x^T x'$ ；距离结果强依赖尺度、特征与不变性，可对旋转/平移变换取最大相似。**聚类**
K-Means 目标 $J = \sum_k \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$ ：随机选 K 中心，然后交替

$$c_i = \operatorname{argmin}_k \|x_i - \mu_k\|^2, \qquad \mu_k = |C_k|^{-1} \sum_{i \in C_k} x_i$$

至稳定。每步不增 J ，只保局部最优；依赖初始化/量纲/ K ，多重启或 K-Means++，先标准化。若题给距离（如 Manhattan $|x_1 - x'_1| + |x_2 - x'_2|$ ），分配簇时严格用题给距离。凝聚层次聚类：每点一簇，反复合并最近两簇得 dendrogram；single、complete、average linkage 分别取跨簇最小、最大、平均距离（single 易链化，complete 较紧凑）。**K-NN** 的 K 是邻居数；**K-Means** 的 K 是簇数。

10 深度学习基础

DL 用多层网络自动学习层次表示、端到端处理高维输入；代价是数据、算力、训练时间。通用逼近定理说宽单隐层可逼近连续函数，不代表浅层总是高效或深层必定更好；隐藏层更多通常容量更大、过拟合风险更高，不是“更不易过拟合”。基本层：输入层/隐藏层/输出层，“状态层”不是普通 NN 层。

前向： $z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)}$, $a^{(l)} = \sigma(z^{(l)})$ 。参数数 $\sum_l n_l (n_{l-1} + 1)$ （权重 + 偏置；输入节点无参数）。无非线性时多层线性仍等价单层线性。单层感知器逻辑门： $y = 1[w_0 + \sum_i w_i x_i \geq 0]$, AND 需 $(1, 1)$ 过阈值（例 $[-2, 1, 1.5]$ ）。

激活	定义/范围	要点
Sigmoid	$(1 + e^{-x})^{-1}$, $(0, 1)$	饱和、非零中心
Tanh	$2\sigma(2x) - 1$, $(-1, 1)$	零中心，仍饱和
ReLU	$\max(0, x)$	快；负区梯度 0
Leaky	$\max(\alpha x, x)$	缓解 dying ReLU

$\sigma' = \sigma(1 - \sigma)$, $\tanh' = 1 - \tanh^2$ 。Softmax： $\hat{y}_k = e^{z_k} / \sum_j e^{z_j}$, 和为 1 且 argmax 与 logits 相同；互斥多分类用 Softmax，独立多标签常用多个 Sigmoid。

预处理：中心化；标准化 $(x - \mu)/s$ ；Min-Max；像素 $/255$ 。 μ, s 只从训练集求。

损失：多类 CE $-N^{-1} \sum_{ik} y_{ik} \log \hat{y}_{ik}$ ；one-hot 单样本 $= -\log \hat{y}_c$ ；BCE $-[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$ ；MSE $= N^{-1} \sum (y - \hat{y})^2$ （大误差敏感）；MAE 更抗异常但 0 处不可导。**梯度/反传**： $\theta \leftarrow \theta - \alpha \nabla_{\theta} L$ 。反传是链式法则；对 $z = Wa + b$ ，令 $\delta = \partial L / \partial z$ ： $\partial L / \partial W = \delta a^T$, $\partial L / \partial b = \delta$, $\partial L / \partial a = W^T \delta$ 。Sigmoid+BCE 有 $\partial L / \partial z = \hat{y} - y$ 。非凸损失面不保全局最优。**Sigmoid+MSE 手算**： $\delta_o = (\hat{y} - y^*) \hat{y} (1 - \hat{y})$ ； $\delta_h = (V \delta_o) \odot h(1 - h)$ ； $V \leftarrow V - \alpha \delta_o h$, $W \leftarrow W - \alpha \delta_h x^T$ 。先前向，后算误差，再同步更新权重。

Batch/训练计数：Batch GD 用全量、SGD 用 1 个、mini-batch

（常用）折中并行与噪声。iteration= 一次更新；epoch= 全数据一遍；每 epoch 步数 $\lceil N/B \rceil$ ，每轮常 shuffle。

Momentum： $v_t = \beta v_{t-1} + \alpha g_t$, $\theta_t = \theta_{t-1} - v_t$ ，在一致方向加速、抑制峡谷震荡。**Adam**： $m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$, $v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$ ；偏差修正 $\hat{m} = m / (1 - \beta_1^t)$, $\hat{v} = v / (1 - \beta_2^t)$ ； $\theta \leftarrow \theta - \alpha \hat{m} / (\sqrt{\hat{v}} + \epsilon)$ ，常用 .9, .999, 10^{-8} 。学习率过大则震荡/发散，过小则收敛慢；调度：阶梯、指数、余弦、平台降低、warmup。学习率是超参数，不由反传直接学习。**泛化**：欠拟合 = 训练/验证误差都高；过拟合 = 训练很低、验证高。对策：更多数据/更合适容量、正则化。**L2**： $L + \lambda \sum \theta^2$ ，整体缩小；**L1**： $L + \lambda \sum |\theta|$ ，促稀疏；Dropout 训练随机丢单元、测试用完整网络并保持期望尺度（先辨 p 是保留还是丢弃）；Early stopping 保存最佳验证模型，patience 后停止并恢复。

超参包括层数/宽度、激活/损失、优化器、学习率、batch、正则强度等；均用验证集。Grid 全枚举，Random 在高维常更高效，Bayesian optimization 利用既有试验选下一点。**易错** 测试集不能反复用于模型选择；否则数据泄漏。

11 考场检查清单

- 搜索题：先写 b, s, m, C^*, ϵ 与停止条件；区分树/图搜索。
- CSP：变量–域–约束不重不漏；弧相容删尾；MRV 选变量、LCV 选值。
- 概率题：先按图分解；证据条件化；隐藏变量求和；最后归一化。
- MDP/RL： V 先选动作， Q 固定首动作；MDP 已知 T, R , RL 未知；TD 用策略下一状态，Q-learning 用 $\max Q$ 。
- ML/DL 手算：写未归一化分数/维度/偏置；GD 必沿负梯度；参数量别漏 bias；CE 只取真实类。