

1. 以下是隐马尔可夫模型（Hidden Markov Models）前向算法更新的完整推导。我们使用 $e_{1:t}$ 表示所有证据变量。

$$P(x_t | e_{1:t}) \propto P(x_t, e_{1:t}) \quad (1)$$

$$= \sum_{x_{t-1}} P(x_{t-1}, x_t, e_{1:t}) \quad (2)$$

$$= \sum_{x_{t-1}} P(x_{t-1}, x_t, e_{1:t-1}, e_t) \quad (3)$$

$$= \sum_{x_{t-1}} P(e_t | x_{t-1}, x_t, e_{1:t-1}) P(x_{t-1}, x_t, e_{1:t-1}) \quad (4)$$


$$= \sum_{x_{t-1}} P(e_t | x_t) P(x_{t-1}, x_t, e_{1:t-1}) \quad (5)$$

$$= \sum_{x_{t-1}} P(e_t | x_t) P(x_t | x_{t-1}, e_{1:t-1}) P(x_{t-1}, e_{1:t-1}) \quad (6)$$

$$= \sum_{x_{t-1}} P(e_t | x_t) P(x_t | x_{t-1}) P(x_{t-1}, e_{1:t-1}) \quad (7)$$

$$= P(e_t | x_t) \sum_{x_{t-1}} P(x_t | x_{t-1}) P(x_{t-1}, e_{1:t-1}) \quad (8)$$

$$\propto P(e_t | x_t) \sum_{x_{t-1}} P(x_t | x_{t-1}) P(x_{t-1} | e_{1:t-1}) \quad (9)$$



- (1) 下列哪些假设能够支持从步骤 (4) 推导到步骤 (5)? 可多选。

- | | |
|--|--|
| ☐ $E_t \perp\!\!\!\perp X_{t-1} X_t$ | ☐ $E_t \perp\!\!\!\perp E_k X_{t-1}$ for all $1 \leq k \leq t-1$ |
| ☐ $E_t \perp\!\!\!\perp E_k X_t$ for all $1 \leq k \leq t-1$ | ☐ $X_t \perp\!\!\!\perp E_{t+1} X_{t+1}$ |
| ☐ $E_t \perp\!\!\!\perp E_k$ for all $1 \leq k \leq t-1$ | ☐ $X_t \perp\!\!\!\perp E_k X_{t-1}$ for all $1 \leq k \leq t-1$ |
| ☐ $E_t \perp\!\!\!\perp E_{t+1} X_t$ | ☐ none |


- (2) 下列哪些假设能够支持从步骤 (5) 推导到步骤 (6)? 可多选。

- | | |
|--|--|
| ☐ $E_t \perp\!\!\!\perp X_{t-1} X_t$ | ☐ $E_t \perp\!\!\!\perp E_k X_{t-1}$ for all $1 \leq k \leq t-1$ |
| ☐ $E_t \perp\!\!\!\perp E_k X_t$ for all $1 \leq k \leq t-1$ | ☐ $X_t \perp\!\!\!\perp E_{t+1} X_{t+1}$ |
| ☐ $E_t \perp\!\!\!\perp E_k$ for all $1 \leq k \leq t-1$ | ☐ $X_t \perp\!\!\!\perp E_k X_{t-1}$ for all $1 \leq k \leq t-1$ |
| ☐ $E_t \perp\!\!\!\perp E_{t+1} X_t$ | ☐ none |

- (3) 下列哪些假设能够支持从步骤 (6) 推导到步骤 (7)? 可多选。

- | | |
|--|--|
| ☐ $E_t \perp\!\!\!\perp X_{t-1} X_t$ | ☐ $E_t \perp\!\!\!\perp E_k X_{t-1}$ for all $1 \leq k \leq t-1$ |
| ☐ $E_t \perp\!\!\!\perp E_k X_t$ for all $1 \leq k \leq t-1$ | ☐ $X_t \perp\!\!\!\perp E_{t+1} X_{t+1}$ |
| ☐ $E_t \perp\!\!\!\perp E_k$ for all $1 \leq k \leq t-1$ | ☐ $X_t \perp\!\!\!\perp E_k X_{t-1}$ for all $1 \leq k \leq t-1$ |
| ☐ $E_t \perp\!\!\!\perp E_{t+1} X_t$ | ☐ none |

- (4) 隐马尔可夫模型可以通过多种方式进行扩展，以纳入额外的关系。由于这些扩展后的隐马尔可夫模型所满足的独立性假设不同，其前向算法的更新公式也会有所不同。请针对以下贝叶斯网络（Bayes nets）所对应的扩展隐马尔可夫模型，请推导并补全前向算法的更新公式：



$$P(x_t | e_{1:t}) \propto \sum_{x_{t-1}} P(x_{t-1} | e_{1:t-1}) \cdot \underline{P(e_t | x_t, x_{t-1})P(x_t | x_{t-1})}$$

$$\begin{aligned} P(x_t | e_{1:t}) &\propto P(x_t, e_{1:t}) = \sum_{x_{t-1}} P(x_{t-1}, x_t, e_{1:t-1}, e_t) \\ &= \sum_{x_{t-1}} P(e_t | x_t, x_{t-1}) P(x_{t-1}, x_t, e_{1:t-1}) \\ &= \sum_{x_{t-1}} P(e_t | x_t, x_{t-1}) P(x_{t-1}, x_t, e_{1:t-1}) \\ &= \sum_{x_{t-1}} P(e_t | x_t, x_{t-1}) P(x_t | x_{t-1}) P(x_{t-1}, e_{1:t-1}) \\ &= \sum_{x_{t-1}} P(e_t | x_t, x_{t-1}) P(x_t | x_{t-1}) P(x_{t-1} | e_{1:t-1}) \\ &\propto \sum_{x_{t-1}} P(e_t | x_t, x_{t-1}) P(x_t | x_{t-1}) P(x_{t-1} | e_{1:t-1}) \end{aligned}$$

- (5) 考虑第 (4) 问中的隐马尔科夫模型，设 X 有 $+x, -x$ 两种状态， E 可观测到 e_1, e_2 两种状态，结合如下条件概率表，分别求观测到 $E_1 = e_1, E_2 = e_2, t = 1, 2$ 时的前向概率 $B(X_t) = P(X_t | e_{1:t})$ ，结果保留 3 位小数。

X_{t-1}	X_t	$P(X_t X_{t-1})$
$+x$	$+x$	0.8
$+x$	$-x$	0.2
$-x$	$+x$	0.4
$-x$	$-x$	0.6

X_{t-1}	X_t	E_t	$P(E_t X_t, X_{t-1})$
$+x$	$+x$	e_1	0.2
$+x$	$-x$	e_1	0.8
$-x$	$+x$	e_1	0.4
$-x$	$-x$	e_1	0.7
$+x$	$+x$	e_2	0.8
$+x$	$-x$	e_2	0.2
$-x$	$+x$	e_2	0.6
$-x$	$-x$	e_2	0.3

$$\begin{aligned} P(+x) &= P(+x | +x)P(+x) + P(+x | -x)P(-x) \\ P(+x) &= 0.8P(+x) + 0.4P(-x), \quad P(+x) + P(-x) = 1 \\ \Rightarrow P(+x) &= 2P(-x), \quad B(x_0 = +x) = \frac{2}{3}, \quad B(x_0 = -x) = \frac{1}{3}. \end{aligned}$$

$$\begin{aligned}\tilde{B}(x_1 = +x) &= P(e_1 \mid +x, +x)P(+x \mid +x)B(x_0 = +x) + P(e_1 \mid +x, -x)P(+x \mid -x)B(x_0 = -x) \\ &= 0.2 \times 0.8 \times \frac{2}{3} + 0.4 \times 0.4 \times \frac{1}{3} = 0.160,\end{aligned}$$

$$\begin{aligned}\tilde{B}(x_1 = -x) &= P(e_1 \mid -x, +x)P(-x \mid +x)B(x_0 = +x) + P(e_1 \mid -x, -x)P(-x \mid -x)B(x_0 = -x) \\ &= 0.8 \times 0.2 \times \frac{2}{3} + 0.7 \times 0.6 \times \frac{1}{3} = 0.247.\end{aligned}$$

$$B(x_1 = +x) = \frac{0.160}{0.160 + 0.247} = 0.393,$$

$$B(x_1 = -x) = \frac{0.247}{0.160 + 0.247} = 0.607.$$

$$\begin{aligned}\tilde{B}(x_2 = +x) &= P(e_2 \mid +x, +x)P(+x \mid +x)B(x_1 = +x) + P(e_2 \mid +x, -x)P(+x \mid -x)B(x_1 = -x) \\ &= 0.8 \times 0.8 \times 0.393 + 0.6 \times 0.4 \times 0.607 = 0.397,\end{aligned}$$


$$\begin{aligned}\tilde{B}(x_2 = -x) &= P(e_2 \mid -x, +x)P(-x \mid +x)B(x_1 = +x) + P(e_2 \mid -x, -x)P(-x \mid -x)B(x_1 = -x) \\ &= 0.2 \times 0.2 \times 0.393 + 0.3 \times 0.6 \times 0.607 = 0.125.\end{aligned}$$

$$B(x_2 = +x) = \frac{0.397}{0.397 + 0.125} = 0.761,$$

$$B(x_2 = -x) = \frac{0.125}{0.397 + 0.125} = 0.239.$$

2. 贝叶斯网络

(1) 条件依赖判断，考虑如下贝叶斯网络：判断如下依赖关系是否成立。



(i) ☐ 成立 ☒ 不成立 $A \perp\!\!\!\perp B$

An active path: $A \rightarrow B$.

(ii) ☒ 成立 ☐ 不成立 $A \perp\!\!\!\perp C$

No active paths.

(iii) ☐ 成立 ☒ 不成立 $A \perp\!\!\!\perp D \mid E$

An active path: $A \rightarrow B \rightarrow E$ (observed) $\leftarrow D$.

(iv) ☐ 成立 ☒ 不成立 $A \perp\!\!\!\perp I \mid E$

An active path: $A \rightarrow B \rightarrow E$ (observed) $\leftarrow D \rightarrow G \rightarrow H \rightarrow I$.

(v) ☐ 成立 ☒ 不成立 $B \perp\!\!\!\perp C \mid I$

An active path: $B \rightarrow E$ (descendent I observed) $\leftarrow F \leftarrow C$.


(vi) ☐ 成立 ☒ 不成立 $F \perp\!\!\!\perp A \mid H$

An active path: $F \rightarrow E$ (descendent H observed) $\leftarrow B \leftarrow A$.

(vii) ☒ 成立 ☐ 不成立 $D \perp\!\!\!\perp I \mid \{E, G\}$
No active paths.

(viii) ☐ 成立 ☒ 不成立 $C \perp\!\!\!\perp H \mid G$
An active path: $C \rightarrow F \rightarrow E \rightarrow H$.

(2) 贝叶斯网络推理, 贝叶斯网络和条件概率表如下, 求 $P(E|+d)$, 结果保留 3 位小数。



A	$P(A)$
$+a$	0.5
$-a$	0.5

C	$P(C)$
$+c$	0.6
$-c$	0.4

A	B	$P(B A)$
$+a$	$+b$	0.1
$+a$	$-b$	0.9
$-a$	$+b$	0.3
$-a$	$-b$	0.7

A	D	$P(D A)$
$+a$	$+d$	0.8
$+a$	$-d$	0.2
$-a$	$+d$	0.5
$-a$	$-d$	0.5

B	C	E	$P(E B,C)$
$+b$	$+c$	$+e$	0.7
$+b$	$+c$	$-e$	0.3
$+b$	$-c$	$+e$	0.2
$+b$	$-c$	$-e$	0.8
$-b$	$+c$	$+e$	0.9
$-b$	$+c$	$-e$	0.1
$-b$	$-c$	$+e$	0.4
$-b$	$-c$	$-e$	0.6

变量消去顺序取为 $C \rightarrow B \rightarrow A$ 。

$$P(E|+d) = \frac{P(+d, E)}{P(+d)}.$$

先消去 C 。将 $P(C)$ 与 $P(E|B,C)$ 合并, 得到 $P(C, E|B)$, 再对 C 求和。

B	C	E	$P(C, E B)$
$+b$	$+c$	$+e$	0.42
$+b$	$+c$	$-e$	0.18
$+b$	$-c$	$+e$	0.08
$+b$	$-c$	$-e$	0.32
$-b$	$+c$	$+e$	0.54
$-b$	$+c$	$-e$	0.06
$-b$	$-c$	$+e$	0.16
$-b$	$-c$	$-e$	0.24

B	E	$P(E B)$
$+b$	$+e$	0.50
$+b$	$-e$	0.50
$-b$	$+e$	0.70
$-b$	$-e$	0.30

再将 $P(E|B)$ 与 $P(B|A)$ 合并, 得到 $P(B, E|A)$, 并对 B 求和得到 $P(E|A)$ 。

A	B	E	$P(B, E A)$
$+a$	$+b$	$+e$	0.05
$+a$	$+b$	$-e$	0.05
$+a$	$-b$	$+e$	0.63
$+a$	$-b$	$-e$	0.27
$-a$	$+b$	$+e$	0.15
$-a$	$+b$	$-e$	0.15
$-a$	$-b$	$+e$	0.49
$-a$	$-b$	$-e$	0.21

A	E	$P(E A)$
$+a$	$+e$	0.68
$+a$	$-e$	0.32
$-a$	$+e$	0.64
$-a$	$-e$	0.36

接着合并 $P(A)$ 、 $P(E|A)$ 与 $P(+d|A)$, 得到 $P(A, +d, E)$, 再对 A 求和得到 $P(+d, E)$ 。

D	E	A	$P(A, D, E)$
$+d$	$+e$	$+a$	0.272
$+d$	$+e$	$-a$	0.160
$+d$	$-e$	$+a$	0.128
$+d$	$-e$	$-a$	0.090

D	E	$P(D, E)$
$+d$	$+e$	0.432
$+d$	$-e$	0.218

再由 $P(A)$ 与 $P(D \mid A)$ 得到

A	D	$P(A, D)$
$+a$	$+d$	0.40
$+a$	$-d$	0.10
$-a$	$+d$	0.25
$-a$	$-d$	0.25

因而

$$P(+d) = 0.40 + 0.25 = 0.65.$$

最后由贝叶斯公式得到

$$\begin{aligned}
 P(+e \mid +d) &= \frac{P(+d, +e)}{P(+d)} = \frac{0.432}{0.65} \approx 0.665, \\
 P(-e \mid +d) &= \frac{P(+d, -e)}{P(+d)} = \frac{0.218}{0.65} \approx 0.335.
 \end{aligned}$$

因此，

$$P(E \mid +d) = \begin{cases} P(+e \mid +d) \approx 0.665, \\ P(-e \mid +d) \approx 0.335. \end{cases}$$

马尔可夫决策过程（MDP）




图 1: 小明的马尔可夫决策过程

小明是《人工智能与物联网》课程的一名学生，正在学习马尔可夫决策过程（MDP）的相关内容，图 1 展示了小明在课堂上的相关动态。

图中，圆圈或矩形表示小明的状态（State），每一条有向边都表示一个可能的转移（Transition），有向边表示小明从一个状态转移到另一个状态采取的动作（Action）以及相应的回报（Reward）。黑色圆点及从黑色圆点出发的边表示小明采取打游戏动作后，转移到不同状态的概率。本题中，折扣因子 $\gamma = 0.9$

1. 现在我们用 $Q^*(s, a)$ 来表示状态 s 下采取动作 a 的最优动作价值函数。考虑从状态 s 采取动作 a 后转移到状态 s' ，并采取动作 a' 的情况，你能给出 $Q^*(s, a)$ 和 $Q^*(s', a')$ 的关系吗？
2. 定义 $\mathcal{V}_\pi$ 是在策略 π 下，状态价值函数组成的矩阵， $\mathcal{R}^\pi$ 是奖励函数组成的矩阵， $\mathcal{T}^\pi$ 是转移概率矩阵， γ 是折扣因子。那么根据 Bellman Equation，我们可以把整个 MDP 形式化为：

$$\mathcal{V}_\pi = \mathcal{R}^\pi + \gamma \mathcal{T}^\pi \mathcal{V}_\pi$$

一个好消息是这个等式是线性的，那么在满足一定条件的情况下，我们可以直接解出整个 MDP 的状态价值：

$$\mathcal{V}_\pi = (I - \gamma \mathcal{T}^\pi)^{-1} \mathcal{R}^\pi$$

但对于大型 MDP，求出 $I - \gamma \mathcal{T}^\pi$ 的逆矩阵通常比较困难。价值迭代（Value Iteration）是一个常用的数值方法来求解 MDP 的状态价值，请你根据课上讲的求解价值迭代的相关方法，写出价值迭代的更新公式，并完成下面的表格：

表 1: 价值迭代过程表					
迭代次数 k	摸鱼	阶段 1	阶段 2	阶段 3	睡觉
0	0	0	0	0	0
1					
2					
3					
4					
5					

3. 现在我们知道小明的动作空间是 $\mathcal{A} = \{\text{摸鱼, 学习, 退出摸鱼, 打游戏, 睡觉}\}$ ；请你根据 Bellman Equation 和刚刚计算出的 V^* 值，填写下面的表格：

表 2: 最优动作价值函数表						
状态 s	摸鱼	学习	退出摸鱼	打游戏	睡觉	$V^*(s)$
摸鱼		—		—	—	
阶段 1			—	—	—	
阶段 2	—		—	—		
阶段 3	—		—		—	
睡觉	—	—	—	—	—	

现在已经计算出了各个状态-动作对的最优动作价值函数 $Q^*(s, a)$ 。因此，对于每一个状态 s ，我们可以通过 $\pi^*(s) = \arg \max_{a \in \mathcal{A}(s)} Q^*(s, a)$ 确定该状态下的最优动作。假设小明起始位于“摸鱼”状态，请你使用贪心策略，给出小明的最优行动路径。

Solution.

1. 首先有：

$$Q^*(s, a) = \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^*(s')]$$

$$V^*(s) = \max_{a \in \mathcal{A}(s)} Q^*(s, a)$$

因此 $Q^*(s, a) = \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma \max_{a' \in \mathcal{A}(s')} Q^*(s', a')]$.

2. 根据 $V_{k+1}(s) \leftarrow \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V_k(s')]$, 有：

$$V_{k+1}(\text{摸鱼}) = \max \{-1 + 0.9V_k(\text{摸鱼}), 0 + 0.9V_k(\text{阶段1})\}$$

$$V_{k+1}(\text{阶段1}) = \max \{-1 + 0.9V_k(\text{摸鱼}), -2 + 0.9V_k(\text{阶段2})\}$$

$$V_{k+1}(\text{阶段2}) = \max \{-2 + 0.9V_k(\text{阶段3}), 0 + 0.9V_k(\text{睡觉})\}$$

$$V_{k+1}(\text{阶段3}) = \max \{10 + 0.9V_k(\text{睡觉}), 1 + 0.9 [0.2V_k(\text{阶段1}) + 0.4V_k(\text{阶段2}) + 0.4V_k(\text{阶段3})]\}$$

$$V_{k+1}(\text{睡觉}) = 0.$$

状态价值函数表如下所示：

迭代次数 k	摸鱼	阶段 1	阶段 2	阶段 3	睡觉
0	0	0	0	0	0
1	0	-1	0	10	0
2	-0.9	-1	7	10	0
3	-0.9	4.3	7	10	0
4	3.87	4.3	7	10	0
5	3.87	4.3	7	10	0

3. 根据

$$Q^*(s, a) = \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^*(s')]$$

最优动作价值函数如下表所示：

状态 s	摸鱼	学习	退出摸鱼	打游戏	睡觉	$V^*(s)$
摸鱼	2.483	—	3.87	—	—	3.87
阶段 1	2.483	4.3	—	—	—	4.3
阶段 2	—	7	—	—	0	7
阶段 3	—	10	—	7.894	—	10
睡觉	—	—	—	—	—	0

因此最优行动路径为：“退出摸鱼”，“学习”，“学习”，“学习”

Reinforcement Learning

根据 Bellman Equation 及其推导可知，当一个 MDP 的奖励函数 $\mathcal{R}$ 和转移概率 $\mathcal{T}$ 都已知时，我们可以通过求解 Bellman 最优方程得到最优价值函数，并进一步确定最优策略。这类依赖环境模型的方法通常称为 Model-Based 方法。

然而，在现实生活中，我们往往无法提前知道准确的转移概率矩阵 $\mathcal{T}$ 。因此 Model-Free 方法被提出，用于在缺少环境模型的情况下，通过与环境交互获得的经验来学习最优策略。例如，在 Model-Free 方法中，我们可以直接学习动作价值函数 $Q(s, a)$ ，并在此基础上通过贪心方式选择当前估计下的最优动作：

$$\pi'(s) = \arg \max_{a \in \mathcal{A}(s)} Q(s, a).$$

1. 回忆在状态 s ，选择动作 a 时动作价值函数的定义 $Q_\pi(s, a)$ ：

$$\begin{aligned} Q_\pi(s, a) &= \mathbb{E}_\pi [G_t | S_t = s, A_t = a] \\ &= \mathbb{E}_\pi [R_{t+1} + \gamma G_{t+1} | S_t = s, A_t = a] \\ &= \mathbb{E}_\pi [R_{t+1} + \gamma Q_\pi(S_{t+1}, A_{t+1}) | S_t = s, A_t = a] \end{aligned}$$

其中 $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$ 是从时间步 t 开始的折扣回报。可知我们可以用 $R_{t+1} + \gamma Q_\pi(S_{t+1}, A_{t+1})$ 来更新 $Q_\pi(s, a)$

- (a) 请你参照 PPT 中对 Temporal Difference Learning 中相关更新公式的推导，给出对 $Q_\pi(s, a)$ 的更新公式（1-step SARSA）
 - (b) 注意到 G_t 其实还可以写为： $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 G_{t+2}$ ，请你直接给出 2-step SARSA 的更新式
 - (c) 当 G_t 完全展开为 $R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots + \gamma^{T-1} R_T$ 时（ R_T 表示最终奖励）SARSA 将退化为 Monte Carlo 方法（MC），请你分析 MC 方法是如何进行的
2. 在 Model-Free 方法中，智能体通常通过与实际环境交互来获得经验，并基于这些经验学习价值函数或策略。在这一过程中，我们可以区分行为策略（Behavior Policy）和目标策略（Target Policy）：行为策略是智能体实际采取动作并产生样本的策略，目标策略是我们希望评估或优化的策略。当行为策略与目标策略相同时，这类方法称为 on-policy 方法，例如 SARSA；当二者不同时，这类方法称为 off-policy 方法

- (a) 对前述 1-step SARSA 区分行为策略 $A_{t+1} \sim \mu(\cdot | S_{t+1})$ 和目标策略 $A' \sim \pi(\cdot | S_{t+1})$ ，可以写为：

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left(\boxed{R_{t+1} + \gamma Q(S_{t+1}, A')} - Q(S_t, A_t) \right)$$

我们说 Q-Learning 是 off-policy 的，请根据 PPT 中 Q-Learning 中的相关公式，找出 Q-Learning 的行为策略和目标策略

- (b) 请分析 off-policy 方式相较于 on-policy 方式有什么好处

Solution.

1. (a) 1-step SARSA:

$$Q_{\pi}(S_t, A_t) \leftarrow Q_{\pi}(S_t, A_t) + \alpha [R_{t+1} + \gamma Q_{\pi}(S_{t+1}, A_{t+1}) - Q_{\pi}(S_t, A_t)]$$

- (b) 2-step SARSA:

$$Q_{\pi}(S_t, A_t) \leftarrow Q_{\pi}(S_t, A_t) + \alpha [R_{t+1} + \gamma R_{t+2} + \gamma^2 Q_{\pi}(S_{t+2}, A_{t+2}) - Q_{\pi}(S_t, A_t)] .$$

- (c) Monte Carlo 方法和 SARSA 不同点在于, MC 实际上是进行了一个完整的 episode, 这意味着智能体从初始状态开始, 执行一个完整的序列, 直到达到终止状态, 然后根据整个序列的回报来更新价值函数。

2. (a) Q-Learning 的目标策略是:

$$\pi(S_{t+1}) = \arg \max_{a' \in \mathcal{A}(S_{t+1})} Q(S_{t+1}, a').$$

行为策略通常是带探索的策略, 例如 ϵ -greedy 策略:

$$\mu(a | s) = \begin{cases} \epsilon/m + 1 - \epsilon, & \text{if } a = \arg \max_{a' \in \mathcal{A}(s)} Q(s, a'), \\ \epsilon/m, & \text{otherwise.} \end{cases}$$

其中 $m = |\mathcal{A}(s)|$ 表示状态 s 下可选动作的数量。

- (b) 与 on-policy 方法相比, off-policy 方法允许智能体使用一种行为策略与环境交互, 同时学习另一种目标策略。因此, 智能体可以通过较强的探索策略收集经验, 并利用这些经验去优化更接近最优的目标策略。这样做提高了探索灵活性和样本利用率, 也使得历史经验能够被重复用于学习。