

控制与决策系统仿真：第六章作业

自动化（控制）

1 第一题：数据挖掘的过程与任务

1.1 题目

数据挖掘有哪些过程、有哪些任务？试简单说明。

1.2 分析与解答

数据挖掘是从大量、不完整且含有噪声的数据中发现有效、新颖、可理解知识的过程。其一般过程如下：

1. **问题定义**：明确应用目标、待解决的问题以及评价标准；
2. **数据收集与理解**：从数据库、文件或传感器等来源获取数据，并分析数据含义、规模和质量；
3. **数据预处理**：完成数据清洗、集成、变换、规约和特征选择，处理缺失值、异常值及重复数据；
4. **模型建立**：根据任务选择合适的数据挖掘算法，并利用处理后的数据训练模型；
5. **模式评估**：使用评价指标检验模型效果，筛选有意义、可靠的模式；
6. **知识表示与应用**：通过图表、规则或报告展示结果，并将所得知识用于预测和决策。

数据挖掘的主要任务可分为以下几类：

- **分类**：根据有标签的历史数据学习分类规则，预测新样本所属类别；
- **回归与预测**：建立变量间的数量关系，预测连续数值或未来趋势；
- **聚类**：在没有类别标签的情况下，根据相似性将对象划分为若干组；
- **关联分析**：发现不同项目或属性之间经常同时出现的关系；
- **异常检测**：识别与大多数数据显著不同的少数对象；
- **概念描述**：对数据进行特征概括、比较和总结。

2 第二题：数据分类的过程与评价指标

2.1 题目

数据分类有哪些过程？有哪些评价指标？请说明。

2.2 分析与解答

数据分类属于有监督学习，其基本过程如下：

- 1. **数据准备**：清洗数据、选择特征，并将类别转换为明确的标签；
- 2. **数据集划分**：将数据划分为训练集、验证集和测试集，或采用交叉验证；
- 3. **模型训练**：使用决策树、朴素贝叶斯、支持向量机或神经网络等算法学习分类模型；
- 4. **模型验证与调参**：根据验证结果选择特征、调整参数，避免欠拟合或过拟合；
- 5. **模型测试与应用**：在未参与训练的测试集上评价模型，并用于新样本分类。

对于二分类问题，通常用混淆矩阵统计真正例 TP 、真反例 TN 、假正例 FP 和假反例 FN 。常用评价指标如下：

指标	计算公式	含义
准确率	$\frac{TP + TN}{TP + TN + FP + FN}$	全部样本中预测正确的比例
精确率	$\frac{TP}{TP + FP}$	预测为正类的样本中实际为正类的比例
召回率	$\frac{TP}{TP + FN}$	实际正类样本中被正确识别的比例
特异度	$\frac{TN}{TN + FP}$	实际负类样本中被正确识别的比例
F_1 值	$\frac{2PR}{P + R}$	精确率 P 与召回率 R 的调和平均

此外，**ROC 曲线**描述不同分类阈值下真正例率与假正例率的关系；其曲线下面积 **AUC** 越接近 1，模型整体分类能力越强。对于类别不均衡问题，仅使用准确率可能产生误导，应重点考察精确率、召回率、 F_1 值和 AUC。多分类问题可对各类别分别计算指标，再进行宏平均或微平均。

3 第三题：传统聚类方法及聚类过程

3.1 题目

传统的聚类方法有几种？聚类过程有哪些？

3.2 分析与解答

传统聚类方法通常分为以下五类：

1. **划分聚类**：将数据直接划分为 k 个簇，代表方法有 K-means 和 K-medoids；
2. **层次聚类**：通过不断合并或分裂簇形成树状结构，包括凝聚式和分裂式两种；
3. **基于密度的聚类**：将高密度区域连接成簇，并可识别噪声，代表方法为 DBSCAN；
4. **基于网格的聚类**：将数据空间划分为有限网格，再在网格上完成聚类，适合大规模数据；
5. **基于模型的聚类**：假设数据由某种概率模型生成，通过参数估计确定簇，代表方法为高斯混合模型。

聚类分析的一般过程如下：

1. **明确目标**：确定聚类对象、应用目的及需要得到的簇结构；
2. **数据预处理**：处理缺失值和异常值，并对不同量纲的特征进行标准化；
3. **特征与相似度选择**：选择有效特征，并确定欧氏距离、曼哈顿距离或余弦相似度等度量；
4. **选择算法及参数**：根据数据分布选择聚类方法，并设置簇数、邻域半径等参数；
5. **执行聚类**：运行算法，将相似对象划入同一簇；
6. **结果评价与解释**：使用轮廓系数、簇内平方和等指标评价结果，并结合实际含义解释各簇。

4 第四题：关联算法的步骤

4.1 题目

关联算法有哪些步骤？

4.2 分析与解答

关联分析用于从事务数据中发现项目之间的共现关系，典型结果为关联规则 $X \Rightarrow Y$ ，其中 $X \cap Y = \emptyset$ 。常用指标为：

$$\text{support}(X \Rightarrow Y) = \frac{\text{count}(X \cup Y)}{N}, \quad \text{confidence}(X \Rightarrow Y) = \frac{\text{support}(X \cup Y)}{\text{support}(X)}.$$

其中，支持度表示规则在全部事务中出现的频繁程度，置信度表示事务包含 X 时同时包含 Y 的概率。以经典 Apriori 算法为例，关联规则挖掘的步骤如下：

1. **数据准备**：将原始数据整理成事务集合，并设定最小支持度和最小置信度；
2. **生成频繁 1 项集**：统计每个项目的支持度，删除低于最小支持度的项目；
3. **连接与剪枝**：由频繁 k 项集连接生成候选 $(k+1)$ 项集；若候选项集的某个子集不频繁，则依据 Apriori 性质将其删除；
4. **重复搜索频繁项集**：扫描事务数据库，计算候选项集支持度并保留频繁项集，直至无法生成新的频繁项集；
5. **生成关联规则**：将每个频繁项集划分为前件和后件，计算规则置信度，保留满足最小置信度的规则；
6. **评价与筛选**：利用提升度等指标排除无实际意义的规则，并结合业务背景解释结果。

提升度定义为

$$\text{lift}(X \Rightarrow Y) = \frac{\text{confidence}(X \Rightarrow Y)}{\text{support}(Y)}.$$

当提升度大于 1 时，通常说明 X 的出现对 Y 的出现具有正向关联作用。